

Aplicación de Métodos de Minería de Datos para la Caracterización y Clasificación de Homicidios en Colombia (2015-2023)

Y.Y. Mora Segura, A.D. Ramírez Chiquillo, J.D. Ramirez Castañeda

Abstract—This article presents a comprehensive data mining approach for characterizing and classifying homicides in Colombia (2015-2023). Using a dataset of 111,263 records from Colombia's Open Data portal, we conducted exploratory data analysis, data preprocessing, association rule mining, clustering analysis, and supervised classification. The methodology includes handling missing values, categorical variable standardization, and feature selection based on entropy and statistical association metrics. Association rule mining with Apriori and FP-Growth algorithms revealed specific risk profiles, including gender-based violence patterns. Clustering analysis using DBSCAN, GMM, and K-modes identified latent homogeneous profiles at both national and local (Bogotá) levels. Finally, supervised classification using different methods like Gradient boosting, Random forest, neuronal networks, among others, achieved great results for predicting homicide circumstances. Results provide evidence-based insights for differentiated public policy design and violence prevention strategies.

Index Terms—Exploratory data analysis, homicides, Colombia, preprocessing, classification, association rules, clustering, data mining, risk profiles.

I. INTRODUCCIÓN

EL análisis de datos de eventos violentos como los homicidios es fundamental para obtener una comprensión profunda de sus raíces, los entornos en los que ocurren y para la formulación de estrategias de prevención efectivas. Más allá de un análisis exploratorio inicial, la minería de datos permite descubrir patrones complejos, identificar perfiles de riesgo y construir modelos predictivos que pueden apoyar la toma de decisiones informadas en política pública.

Este artículo aplica un enfoque integral de minería de datos al conjunto de homicidios registrados en Colombia entre 2015 y 2023. A partir de un proceso riguroso de preprocesamiento y análisis exploratorio, se implementaron técnicas como reglas de asociación, algoritmos de agrupamiento y modelos de clasificación supervisada. Estas metodologías permitieron no solo caracterizar los homicidios, sino también detectar perfiles latentes y predecir las circunstancias asociadas a los casos. Los resultados obtenidos brindan insumos relevantes para el diseño de intervenciones diferenciadas y estrategias de prevención de la violencia.

II. DESCRIPCIÓN DEL CONJUNTO DE DATOS

El conjunto de datos analizado proviene del portal de Datos Abiertos Colombia, bajo el título “Presuntos Homicidios. Colombia, 2015 a 2023. Cifras definitivas”. Este repositorio contiene registros oficiales de homicidios ocurridos en el

territorio colombiano, recopilados por Instituto Nacional de Medicina Legal y Ciencias Forenses. El dataset completo comprende 111.263 registros de presuntos homicidios, cada uno caracterizado por 35 variables que describen aspectos relacionados con:

- **Características de la víctima:** Información sociodemográfica como edad, sexo, escolaridad, estado civil, país de nacimiento y pertenencia grupal.
- **Características espacio-temporales del hecho:** Ubicación geográfica (departamento, municipio, zona), fecha y franja horaria del suceso.
- **Circunstancias y modalidades del homicidio:** Mecanismo causal, diagnóstico de lesiones, escenario, circunstancia y actividad durante el hecho.
- **Información sobre el presunto agresor:** Cuando está disponible, categorización del autor del homicidio con relación a la víctima.

Es importante destacar que los datos representan “presuntos” homicidios, lo que implica que son casos clasificados preliminarmente como homicidios por las autoridades, pero que podrían estar sujetos a reclasificación posterior durante el proceso judicial [1]. Esta consideración es relevante al momento de interpretar los resultados y establecer conclusiones. La temporalidad del conjunto abarca nueve años (2015-2023), lo que permite observar tendencias y variaciones a lo largo del tiempo. La cobertura geográfica incluye la totalidad del territorio colombiano, con representación de los 32 departamentos y el Distrito Capital, aunque con variaciones significativas en la cantidad de casos registrados por región.

III. ANÁLISIS EXPLORATORIO DEL CONJUNTO DE DATOS

El propósito del Análisis Exploratorio de Datos (AED) realizado fue comprender la estructura, calidad y características principales del conjunto de datos, con particular énfasis en las variables categóricas que conforman la mayoría de los atributos disponibles. Este análisis inicial es fundamental para orientar decisiones de preprocesamiento y para la identificación de variables con potencial explicativo.

1) *Calidad de los datos:* El análisis reveló varios desafíos relacionados con la calidad de los datos:

- **Valores faltantes heterogéneos:** Se identificaron múltiples representaciones de datos ausentes (“No aplica”, “Sin información”, “Desconocido”, espacios en blanco), lo que complicó su cuantificación exacta.

- **Altos porcentajes de datos faltantes en variables clave:** Variables como “Circunstancia del Hecho” (64.16%), “Actividad Durante el Hecho” (38.89%) y “Escolaridad” (21.01%) presentaron porcentajes significativos de valores faltantes.
- **Variables redundantes o no informativas:** Se encontraron siete variables con un único valor (“No aplica”) en todos los registros: “Condición de la Víctima”, “Medio de Desplazamiento”, “Servicio del Vehículo”, “Clase o Tipo de Accidente”, “Objeto de Colisión”, “Servicio del Objeto de Colisión” y “Razón del Suicidio”.
- **Inconsistencias en la codificación:** Se detectaron variaciones ortográficas para la misma categoría en variables como “Escenario del Hecho” (por ejemplo, “Vía pública” y “Vía Pública” como entradas separadas).

Estos hallazgos señalan la necesidad de un preprocesamiento exhaustivo antes de cualquier modelado predictivo.

2) *Distribución temporal de los casos:* El análisis temporal de los homicidios mostró patrones importantes:

- **Tendencia anual:** Se observó una ligera tendencia incremental en el número de homicidios durante el periodo estudiado, con la excepción notable del año 2020, donde se registró una disminución que lo situó en niveles similares a 2017. Esta anomalía podría estar relacionada con las restricciones de movilidad implementadas durante la pandemia de COVID-19, aunque esta hipótesis requeriría análisis adicionales.
- **Estacionalidad mensual:** Los meses con mayor incidencia de homicidios fueron diciembre (10.494 casos) y mayo (9.629 casos), lo que podría relacionarse con periodos festivos y de mayor actividad social.
- **Distribución semanal:** Los días de fin de semana concentraron la mayor cantidad de casos, con el domingo (23.263 casos) y el sábado (17.924 casos) como los días de mayor incidencia.

3) *Patrones espaciales:* La distribución geográfica de los homicidios reveló concentraciones significativas:

- **Concentración urbana:** Las cabeceras municipales registraron 78.280 casos (70.4% del total), mientras que las áreas rurales reportaron 25.891 casos (23.3%) y los centros poblados 5.666 casos (5.1%).
- **Departamentos con mayor incidencia:** Valle del Cauca (21.124 casos), Antioquia (17.133 casos) y Bogotá D.C. (10.412 casos) concentraron el mayor número de homicidios, coincidiendo con las áreas más pobladas del país pero también con zonas históricamente afectadas por diversas dinámicas de violencia.
- **Municipios críticos:** Bogotá D.C. (10.412 casos), Cali (8.997 casos) y Medellín (4.402 casos) fueron los municipios con mayor número absoluto de casos.

Estos patrones espaciales sugieren la importancia de factores urbanos y regionales específicos en la distribución de la violencia homicida.

4) *Perfil demográfico de las víctimas:* Las características sociodemográficas de las víctimas mostraron patrones de vulnerabilidad específicos:

- **Distribución por sexo:** El 91.8% de las víctimas fueron hombres (102.174 casos), frente a un 8.1% de mujeres (8.996 casos), evidenciando un desbalanceo.
- **Grupos etarios:** Los jóvenes adultos entre 20-29 años concentraron la mayor proporción de víctimas (42.314 casos, 38%), seguidos por adultos de 30-39 años (28.367 casos, 25.5%).
- **Nivel educativo:** Entre los datos disponibles, predominaron víctimas con educación básica primaria (35.496 casos) y educación media o secundaria (33.319 casos), sugiriendo una posible relación con condiciones socioeconómicas.
- **Ancestro racial:** La categoría “Mestizo” fue predominante (85.983 casos, 77.3%), seguida de “Negro” (9.645 casos, 8.7%).

Estos resultados señalan la existencia de perfiles de riesgo diferenciados, con una clara sobrerepresentación de hombres jóvenes como víctimas de homicidio.

5) *Características de los homicidios:* El análisis de las modalidades y circunstancias de los homicidios reveló:

- **Mecanismo causal:** El uso de armas de fuego fue el mecanismo predominante (81.790 casos, 73.5%), seguido por armas cortopunzantes (19.406 casos, 17.4%), lo que refleja patrones de acceso y uso de armas en contextos violentos.
- **Escenario del hecho:** La vía pública fue el escenario más común (57.475 casos, 51.7%), seguido por viviendas (14.924 casos, 13.4%) y espacios abiertos como bosques o playas (7.666 casos, 6.9%).
- **Circunstancia del hecho:** Entre los casos con información disponible, destacaron “Ajuste de cuentas” (8.598 casos), “Riña” (7.089 casos) y “Sicariato” (5.749 casos), señalando la relevancia de la violencia instrumental, interpersonal y organizada.
- **Presunto agresor:** El 52.9% de los casos (58.883) no tenían información sobre el agresor, mientras que un 31.3% (34.861) fueron clasificados como “Agresor desconocido”, lo que refleja desafíos importantes para el manejo de datos y uso de futuros modelos de asociación o predicción.

Estos datos proporcionan un panorama sobre las dinámicas predominantes de la violencia homicida en Colombia durante el periodo estudiado.

A. Hallazgos Principales del Análisis Exploratorio

El análisis exploratorio reveló varios aspectos críticos sobre la naturaleza y calidad de los datos:

- **Desafíos de calidad:** La presencia significativa de datos faltantes en variables clave constituye un desafío metodológico importante, que requerirá estrategias específicas de imputación o incorporación explícita de la ausencia de información como una categoría analítica.
- **Patrones temporoespaciales:** La distribución de homicidios muestra patrones claros en términos temporales (mayor incidencia en fines de semana y meses específicos) y espaciales (concentración en cabeceras mu-

nicipales y departamentos específicos), que deben ser considerados en la interpretación y modelado.

- **Perfiles demográficos:** La clara sobrerepresentación de hombres jóvenes entre las víctimas señala la necesidad de explorar factores específicos de género y edad en la violencia homicida.
- **Modalidades predominantes:** El predominio de armas de fuego, escenarios públicos y circunstancias relacionadas con ajustes de cuentas, riñas y sicariato apunta hacia la coexistencia de diversas formas de violencia (organizada, interpersonal, oportunista).

Estos hallazgos sientan las bases para las decisiones de preprocesamiento y selección de características que se abordan en las siguientes secciones.

IV. PREPROCESAMIENTO DE DATOS

Basados en los hallazgos del análisis exploratorio, se desarrolló una estrategia integral de preprocesamiento para abordar los desafíos identificados y preparar los datos para análisis más avanzados.

A. Estrategia de Limpieza y Transformación

1) *Eliminación de variables no informativas:* Se identificaron y eliminaron variables que no aportaban información relevante:

- **Variables con un único valor:** Se eliminaron siete variables que contenían “No aplica” en todos los registros: “Condición de la Víctima”, “Medio de Desplazamiento”, “Servicio del Vehículo”, “Clase o Tipo de Accidente”, “Objeto de Colisión”, “Servicio del Objeto de Colisión” y “Razón del Suicidio”.
- **Variables redundantes:** Se eliminaron códigos DANE duplicados y se optó por mantener solo “Edad natural”, eliminando “Edad judicial” y “Ciclo Vital” por redundancia informativa.

2) *Estandarización de categorías:* Se identificaron y corrigieron inconsistencias en la codificación de variables categóricas:

- **Corrección de errores tipográficos:** Se identificaron y unificaron categorías duplicadas en variables como “Escenario del Hecho” y “Estado Civil” (Por ejemplo “Vía pública” y “Vía Pública”).
- **Estandarización de valores faltantes:** Se normalizaron las diversas representaciones de datos ausentes (“Sin información”, “Desconocido”, espacios en blanco) a un formato consistente.

B. Manejo de Datos Faltantes

La estrategia para el tratamiento de valores faltantes varió según la naturaleza y porcentaje de ausencia en cada variable:

1) *Eliminación de registros:* Se aplicó eliminación selectiva para:

- **Variables críticas con bajo porcentaje de faltantes:** Se eliminaron registros con valores faltantes en “Edad” (0.1%) y “Fecha” (0.21%), ya que estas variables son fundamentales y su porcentaje de ausencia era mínimo.

2) *Imputación de valores:* Se realizaron imputaciones para:

- **Variables categóricas con niveles moderados de ausencia:** En “Pertenencia Grupal” (16.81% de datos faltantes), se imputó la categoría modal “Ninguno”, bajo el supuesto de que la ausencia de información sobre pertenencia grupal suele indicar ausencia de pertenencia específica.

3) *Inclusión explícita de valores faltantes:* Para variables con alto porcentaje de datos ausentes:

- **Incorporación como categoría analítica:** En variables como “Circunstancia del Hecho” (64.16% de ausencia) y “Actividad Durante el Hecho” (38.89% de ausencia), la categoría “Sin información” se mantuvo como una categoría válida para el análisis, reconociendo que la ausencia de datos puede ser informativa en sí misma.

C. Agrupación de Categorías

Para abordar la alta cardinalidad y la presencia de categorías raras, se implementaron estrategias de agrupación:

1) *Agrupación por frecuencia:*

- **Umbral de frecuencia:** Se estableció un umbral del 1% para identificar categorías poco frecuentes, que fueron candidatas para agrupación.
- **Categoría “Otros”:** Se creó una categoría “Otros” para agrupar valores con frecuencia inferior al umbral establecido en variables como “País de Nacimiento de la Víctima”, donde las categorías distintas a “Colombia” y “Venezuela” representaban menos del 2% de los casos totales.

2) *Agrupación conceptual:* Para la variable “Circunstancia del Hecho”, se realizó una agrupación basada en criterios conceptuales:

- **Violencia interpersonal:** Agrupando categorías como “Riña”, “Violencia de pareja” y “Celos”.
- **Crimen organizado/sicariato:** Unificando “Sicariato”, “Ajuste de cuentas” y “Hurto”.
- **Conflicto armado/terrorismo:** Incluyendo “Acción grupos alzados al margen de la ley”, “Enfrentamiento armado” y “Acto terrorista”.
- **Violencia institucional/Estado:** Agrupando “Acción militar”, “Intervención Legal” y “Retención legal”.
- **Violencia contra población vulnerable:** Unificando “Feminicidio”, “Violencia a niños, niñas y adolescentes” y “Violencia al adulto mayor”.

Esta agrupación redujo las 50 categorías originales a un conjunto más manejable de 7 categorías principales, facilitando el análisis y potencial modelado posterior.

D. Codificación para Modelado

Para preparar los datos para su uso en modelos estadísticos o de aprendizaje automático, se aplicaron estrategias de codificación:

- **One-hot encoding:** Se aplicó a variables categóricas con número limitado de categorías (menos de 10), como “Sexo”, “Estado Civil” y “Grupo Mayor Menor de Edad”. Este método permite transformar variables categóricas en representaciones numéricas manteniendo toda la información sin establecer relaciones de ordinalidad.

V. SELECCIÓN DE CARACTERÍSTICAS

Durante esta fase se realizó un análisis exploratorio detallado con el objetivo de identificar las variables categóricas más relevantes para el análisis posterior. Se utilizaron técnicas estadísticas y métricas de información que permiten evaluar tanto la variabilidad interna de los atributos como las relaciones entre ellas. Las principales técnicas empleadas fueron el análisis de entropía, la prueba de Chi-cuadrado y el coeficiente V de Cramer, seleccionadas por su capacidad para evaluar variables categóricas de forma objetiva y cuantificable [4].

A. Distribuciones y Entropía

Se comenzó con un análisis de las distribuciones de frecuencia de las variables categóricas utilizando conteos (`value_counts`) para detectar concentraciones en ciertas categorías. Por ejemplo, se observaron distribuciones muy dominadas por categorías como “Hombre” en “Sexo de la víctima” o “Colombia” en “País de nacimiento de la víctima”, lo cual sugiere baja variabilidad.

Para cuantificar esta variabilidad se utilizó la entropía, una medida derivada de la teoría de la información [5]. La entropía se define como:

$$H(X) = - \sum_{i=1}^n p(x_i) \log_2 p(x_i)$$

donde $p(x_i)$ es la probabilidad de ocurrencia de la categoría x_i de una variable categórica X . Una entropía más alta indica que los valores están más distribuidos entre las categorías posibles, lo cual sugiere una mayor capacidad de la variable para diferenciar entre observaciones.

Esta métrica permitió identificar variables con alta riqueza informativa, tales como:

- Municipio del hecho DANE (entropía: 5.198)
- Departamento del hecho DANE (2.899)
- Mes del hecho (2.483)
- Escenario del hecho (1.849)
- Escolaridad (1.798)
- Actividad durante el hecho (1.753)
- Rango de hora del hecho (1.539)

Estas variables, por su distribución uniforme de valores, poseen un alto potencial para aportar información relevante en análisis descriptivos o modelos predictivos.

B. Relaciones Entre Variables

Para evaluar la relación entre variables categóricas, se recurrió a la prueba de Chi-cuadrado y al coeficiente V de Cramer [6].

Estas herramientas permiten identificar asociaciones estadísticas entre pares de variables.

a) *Chi-cuadrado*: La prueba de Chi-cuadrado (χ^2) evalúa si existe una relación estadísticamente significativa entre dos variables categóricas. Se calcula a partir de una tabla de contingencia y compara las frecuencias observadas con las esperadas bajo la hipótesis de independencia:

$$\chi^2 = \sum \frac{(O - E)^2}{E}$$

donde O es la frecuencia observada y E la esperada. Un valor alto de χ^2 y un p-valor bajo sugieren una relación significativa entre las variables.

b) *Coeficiente V de Cramer*: El V de Cramer se basa en el estadístico Chi-cuadrado, pero normaliza el resultado en una escala entre 0 y 1, facilitando la comparación de la fuerza de asociación:

$$V = \sqrt{\frac{\chi^2}{n(k-1)}}$$

donde n es el tamaño de la muestra y k es el menor número de categorías entre las dos variables. Un valor cercano a 0 indica independencia, mientras que valores más cercanos a 1 indican una asociación fuerte [6].

El análisis reveló asociaciones significativas, especialmente circunstancia del hecho con “Municipio del hecho” (0.304)

Estas relaciones sugieren que ciertas variables capturan contextos comunes o dependencias importantes entre dimensiones del evento, lo que puede ser aprovechado en tareas de modelado.

C. Selección Basada en Métricas

La decisión de qué variables conservar se basó en una combinación de alta entropía (variabilidad interna) y alta asociación (dependencia estadística con otras variables relevantes). Este enfoque permite reducir la redundancia y seleccionar un subconjunto de características más informativo y eficiente.

Las variables prioritarias identificadas incluyen:

- Municipio del hecho DANE: Máxima entropía (5.198), útil para patrones espaciales.
- Escenario del hecho y Actividad durante el hecho: Alta entropía y correlaciones significativas, aportan contexto situacional.
- Circunstancia del hecho: Aunque con datos faltantes, muestra diversidad y asociaciones relevantes.
- Grupo de edad de la víctima y Mes del hecho: Representan dimensiones demográficas y temporales con buena variabilidad.

Su combinación facilita una selección de características objetiva, interpretable y basada en evidencia, lo cual es crucial para el éxito de modelos predictivos y para generar análisis descriptivos robustos.

VI. ANÁLISIS DE REGLAS DE ASOCIACIÓN

Para complementar el análisis exploratorio y descubrir patrones de coocurrencia no evidentes entre las características de los homicidios, se aplicaron técnicas de minería de reglas de asociación. El objetivo de este análisis fue identificar qué combinaciones de atributos aparecen juntas con frecuencia en los registros, formulando reglas en el formato “SI {A} ENTONCES {B}”. Se utilizaron los algoritmos *Apriori* y *FP-Growth*, implementados a través de la librería *mlxtend*, para llevar a cabo esta tarea.

A. Preparación de Datos para Asociación

El primer paso consistió en adecuar el conjunto de datos para los algoritmos de asociación, lo cual requirió una selección y transformación específica de las variables.

- 1.) *Selección de Características:* Se seleccionó un subconjunto de 9 variables categóricas consideradas relevantes para la identificación de patrones contextuales y demográficos, basándose en los hallazgos del análisis exploratorio. Las variables incluidas fueron: 'Grupo de edad de la víctima', 'Sexo de la víctima', 'Mes del hecho', 'Día del hecho', 'Rango de Hora del Hecho X 3 Horas', 'Escenario del Hecho', 'Zona del Hecho', 'Mecanismo Causal' y 'Ancestro Racial'.
- 2.) *Transformación a Formato Transaccional:* Los algoritmos de asociación requieren que los datos estén en un formato de matriz binaria, donde cada fila representa una transacción (en este caso, un homicidio) y cada columna representa un ítem (una característica específica, como 'Sexo_de_la_victima_Hombre'). Para lograr esto, se aplicó la técnica de *one-hot encoding* al subconjunto de datos seleccionado. Esta transformación resultó en una matriz de 111.029 transacciones y 115 ítems únicos.

B. Metodología y Generación de Reglas

La generación de reglas se fundamentó en tres métricas clave para evaluar su relevancia y fiabilidad:

- **Soporte (Support):** Mide la frecuencia de un conjunto de ítems en el total de transacciones. Indica la popularidad de un patrón.
- **Confianza (Confidence):** Mide la probabilidad de que ocurra el consecuente {B} de una regla, dado que ya ocurrió el antecedente {A}. Representa la fiabilidad de la inferencia.
- **Elevación (Lift):** Mide cuánto más probable es que ocurra el consecuente {B} cuando el antecedente {A} está presente, en comparación con la probabilidad de que {B} ocurra por sí solo. Un valor de *lift* > 1 indica una asociación positiva y, por tanto, una regla potencialmente interesante.

Para definir los parámetros de los algoritmos, se utilizó el método del codo (*Elbow Method*), graficando el número de conjuntos de ítems frecuentes encontrados para distintos umbrales de soporte. Aunque no se observó un "codo" pronunciado, se seleccionó un **soporte mínimo de 0.05**, ya que ofrecía un equilibrio entre obtener un número manejable de reglas significativas y no descartar patrones relevantes.

Con este soporte, se aplicaron tanto *Apriori* como *FP-Growth*, obteniendo en ambos casos 649 conjuntos de ítems frecuentes. A partir de estos, se generaron reglas de asociación que fueron filtradas para conservar únicamente aquellas con un **lift** > 1.2 y una **confianza** > 0.6, resultando en un conjunto final de 97 reglas significativas. La validación cruzada entre ambos algoritmos confirmó que el conjunto

de reglas generado fue idéntico, asegurando la robustez del resultado.

C. Hallazgos Principales del Análisis de Asociación

El análisis de las 97 reglas finales, junto con el análisis específico sobre víctimas mujeres, reveló perfiles y contextos de riesgo muy definidos. A continuación, se presentan algunos de los hallazgos más destacados que ilustran la diversidad de los patrones encontrados.

- 1.) *Patrón de Violencia Urbana con Arma Blanca:* La regla con la mayor elevación (*lift*: 1.37) en el análisis general, indica una asociación fuerte e inesperada entre el tipo de arma y el contexto demográfico-geográfico.

SI el escenario del hecho es la **vía pública** y el mecanismo causal es un **arma cortopunzante**, **ENTONCES** la víctima es un **hombre** de ancestro **mestizo** y el crimen ocurre en una **cabecera municipal**.

Con una confianza del 69.2%, esta regla sugiere que la combinación de un ataque con arma blanca en la vía pública incrementa en un 37% la probabilidad de que el perfil de la víctima y el lugar correspondan a un hombre mestizo en un área urbana.

- 2.) *Asociación entre Víctimas Jóvenes y Armas de Fuego:* Otro patrón distintivo de alto interés (*lift*: 1.30) vincula directamente al grupo etario de 20 a 24 años con el uso de armas de fuego en el conjunto de datos general.

SI el escenario es la **vía pública** y la víctima tiene entre **20 y 24 años**, **ENTONCES** la víctima es un **hombre**, el hecho ocurre en una **cabecera municipal** y el mecanismo es un **proyector de arma de fuego**.

Esta regla define un perfil de riesgo muy específico: los hombres jóvenes en espacios públicos no solo son víctimas frecuentes, sino que su situación está fuertemente asociada a la violencia con armas de fuego en centros urbanos.

- 3.) *Perfil de Violencia contra la Mujer con Arma de Fuego:* Al filtrar los datos para analizar únicamente los registros de víctimas mujeres, emergió un patrón revelador sobre la violencia de género.

SI la víctima es **mujer**, de ancestro **mestizo** y el hecho ocurre en la **vía pública**, **ENTONCES** el mecanismo causal es un **proyector de arma de fuego**.

Con una elevación (*lift*) de 1.30, este hallazgo indica que para una mujer mestiza en la vía pública, el uso de un arma de fuego como mecanismo causal es un 30% más probable que en el promedio general de los homicidios de mujeres. Esta regla aísla una vulnerabilidad particular y un perfil de violencia de género muy específico.

- 4.) *Fiabilidad del Contexto Urbano en la Violencia General:* Al analizar las reglas de mayor confianza, se confirma la naturaleza urbana de ciertos tipos de violencia. Una de las reglas más fiables (confianza: 90.2%) del análisis general establece que:

SI la víctima es un **hombre** de ancestro **mes-tizo** asesinado con **arma cortopunzante** en la **vía pública**, **ENTONCES** el hecho ocurre en una **cabecera municipal**.

La altísima confianza de esta regla la convierte en una afirmación predictiva robusta.

En general, las reglas extraídas permiten diferenciar perfiles de riesgo clave. Mientras que el perfil masculino está fuertemente ligado a la violencia urbana general, el análisis específico sobre mujeres revela una vulnerabilidad particular al uso de armas de fuego en espacios públicos. Estas asociaciones, cuantificadas a través de métricas como el lift y la confianza, permiten construir perfiles de riesgo detallados que van más allá de las frecuencias simples.

VI. ANÁLISIS DE AGRUPACIÓN (CLUSTERING)

Como complemento al análisis exploratorio y las reglas de asociación previamente desarrollados, se implementó un análisis de agrupación con el objetivo de identificar perfiles homogéneos latentes dentro de los datos de homicidios. Este enfoque no supervisado permite descubrir patrones estructurales sin asumir categorías predefinidas, proporcionando una perspectiva adicional sobre las dinámicas subyacentes de la violencia en Colombia.

A. Diseño Metodológico del Análisis

1) *Estrategia Dual de Análisis*: Se desarrolló un análisis de clustering en dos niveles complementarios para proporcionar una comprensión integral del fenómeno:

- **Análisis Nacional**: Enfocado en la identificación de patrones generales de violencia en Colombia utilizando la totalidad del conjunto de datos. Este nivel permite caracterizar tendencias macroscópicas y identificar perfiles de riesgo transversales al territorio nacional.
- **Análisis Local - Bogotá**: Concentrado específicamente en los homicidios ocurridos en la capital, aprovechando la riqueza informativa del contexto metropolitano para identificar patrones específicos de violencia urbana que pueden diferir de las tendencias nacionales.

Esta estrategia dual facilita el contraste entre patrones generales y especificidades regionales, proporcionando elementos tanto para políticas nacionales como para intervenciones locales focalizadas.

2) *Tratamiento del Desbalance de Datos*: Uno de los principales desafíos metodológicos identificados fue el marcado desbalance de género en los datos originales (aproximadamente 90% hombres vs 10% mujeres). Para el análisis nacional, se implementó una estrategia de balanceamiento mediante selección aleatoria estratificada:

- **Mujeres**: 8,967 casos (totalidad disponible)
- **Hombres**: 11,967 casos (muestra aleatoria con semilla 42 para reproducibilidad)
- **Dataset balanceado final**: 20,934 casos

Este balanceamiento previene que los algoritmos de clustering generen agrupaciones sesgadas únicamente por la diferencia de frecuencias de género, permitiendo que emerjan patrones más complejos y multidimensionales.

3) Selección y Transformación de Variables:

a) *Criterios de Selección*: La selección de variables se fundamentó en los hallazgos del análisis exploratorio previo, priorizando aquellas que mostraron mayor capacidad discriminativa según las métricas de entropía y asociación estadística calculadas anteriormente.

• Variables Nacionales (12 dimensiones):

- Demográficas: Grupo de edad, sexo, escolaridad, ancestro racial
- Evento: Mecanismo causal, diagnóstico topográfico, presunto agresor, zona y escenario del hecho
- Espacio-temporales: Departamento, mes y año del hecho

• Variables Bogotá (15 dimensiones):

- Además de las variables nacionales, se incorporaron dimensiones específicas como localidad del hecho, rango horario y circunstancia del hecho, que proporcionan mayor granularidad para el análisis urbano.

b) Estrategias de Transformación:

• Análisis Nacional:

- Se aplicó una secuencia de transformaciones consistente en: (1) codificación One-Hot Encoding para variables categóricas, (2) normalización con StandardScaler para homogeneizar escalas, y (3) reducción dimensional con PCA para optimizar el rendimiento computacional manteniendo la varianza explicativa.

• Análisis Bogotá:

- Se implementó Análisis de Correspondencias Múltiples (MCA) como técnica de reducción dimensional específicamente diseñada para variables categóricas, transformando las 15 variables originales en coordenadas de 10 dimensiones que preservan la máxima varianza explicada.

Para validar la coherencia interna de los grupos formados, se utilizaron métricas como el coeficiente de Silhouette, el índice de Calinski-Harabasz y el índice de Davies-Bouldin. DBSCAN mostró el mejor desempeño general, especialmente en Bogotá, con el coeficiente de Silhouette más alto (0.826) y el índice Davies-Bouldin más bajo (0.170), lo que sugiere que los clusters son compactos y bien separados (Tabla 1). En el análisis nacional, DBSCAN también alcanzó un valor alto (0.824), lo que respalda la validez de los perfiles generados.

B. Implementación de Algoritmos y Evaluación

1) *Algoritmos Implementados*: Se emplearon cuatro algoritmos complementarios, cada uno con fortalezas específicas para diferentes aspectos del análisis:

• DBSCAN (Density-Based Spatial Clustering):

- Nacional: eps=90, min_samples=2, identificando 2 clusters principales más ruido
- Bogotá: eps=1.5, min_samples=15, con coeficiente de Silhouette de 0.826

• Gaussian Mixture Model (GMM):

- Nacional: 4 componentes óptimos

TABLE I
EVALUACIÓN COMPARATIVA DE ALGORITMOS PARA BOGOTÁ

Algoritmo	N	Silh.	C-H	D-B
K-Modes	10	-0.078	119.863	6.826
K-Means+MCA	3	0.420	940.027	1.916
GMM	10	0.022	518.920	2.370
DBSCAN	2	0.826	860.150	0.170

– Bogotá: 10 componentes con BIC=-122,316.30

• **K-Modes (específico para Bogotá):**

– Algoritmo especializado en variables categóricas con K=10 óptimo (costo: 54,862)

• **K-Means con coordenadas MCA (específico para Bogotá):**

– K=3 óptimo con coeficiente de Silhouette de 0.420

2) *Evaluación Comparativa:* La evaluación se realizó mediante múltiples métricas internas para garantizar la robustez de los resultados:

DBSCAN demostró el mejor desempeño general, particularmente en el análisis de Bogotá, con el coeficiente de Silhouette más alto (0.826) y el índice Davies-Bouldin más bajo (0.170), indicando clusters bien definidos y separados.

C. Caracterización de Perfiles Identificados

1) *Perfiles Nacionales:* El análisis nacional con DBSCAN (coeficiente de silueta promedio = 0.824) identificó cuatro clusters y un grupo de casos atípicos. Cada uno refleja perfiles diferenciados de víctimas de homicidio:

- **Cluster 0 (Mayoritario):** Patrón dominante de violencia interpersonal. Víctimas en su mayoría hombres (57.2%), entre 20 y 34 años, con baja escolaridad y ancestro mestizo. Predomina el uso de arma de fuego (66.9%), lesiones múltiples y ocurrencia en vía pública de cabeceras municipales, especialmente en Valle del Cauca, Antioquia y Bogotá.
- **Cluster 1 (Femenino):** Exclusivo de mujeres (100%) entre 40 y 54 años. Se asocia al uso de agentes cáusticos y escenarios domésticos o rurales. Podría reflejar casos de violencia intrafamiliar o de género.
- **Cluster 2 (Mixto):** Víctimas hombres y mujeres jóvenes (20-29 años), con ataques por arma de fuego. Se presenta en zonas rurales y urbanas, principalmente en Caquetá y Cundinamarca, lo que sugiere posible relación con violencia asociada al conflicto armado.
- **Cluster 3 (Joven masculino):** Exclusivo de hombres entre 18 y 29 años, con estrangulamiento como mecanismo común. Asociado a contextos específicos como estaciones de servicio y viviendas.
- **Casos Atípicos (Ruido -1):** Agrupa víctimas inusuales como niños pequeños o personas con escolaridad extrema. Presenta mecanismos poco frecuentes (asfixia, electricidad, tóxicos) y escenarios rurales o particulares. Aunque escasos, son relevantes por su singularidad.

2) *Perfiles Bogotá:* El análisis específico de Bogotá con DBSCAN (coeficiente de silueta promedio = 0.82) reveló una segmentación tripartita que complementa y detalla las dinámicas urbanas de homicidio:

- **Cluster Principal:** Representa el patrón dominante de violencia urbana. Se caracteriza por una mayoría de víctimas masculinas (91.2%), con alta concentración en el grupo de edad de 20 a 24 años (19.8%). El 98.7% de los casos ocurrieron en cabeceras municipales, principalmente en vía pública (71.1%), con prevalencia del uso de armas de fuego (56.1%) y una marcada concentración temporal en domingos (22.9%). Ciudad Bolívar se destacó como la localidad más afectada (18.8%).
- **Cluster Específico:** Conforman un grupo altamente homogéneo compuesto exclusivamente por víctimas masculinas (100%), en su mayoría jóvenes entre 20 y 24 años (78.9%). El uso de agentes explosivos fue total (100%), y todos los casos se asociaron con contextos de conflicto armado o terrorismo, ocurridos en lugares de esparcimiento.
- **Casos Atípicos (Ruido):** Agrupan modalidades excepcionales de violencia urbana. Presentan mayor diversidad demográfica (24.4% víctimas femeninas) y una notable heterogeneidad en los mecanismos causales, incluyendo agentes tóxicos (17.9%) y múltiples tipos de armas. Su singularidad sugiere fenómenos emergentes que requieren atención diferenciada.

D. Análisis de Aplicaciones

El análisis de agrupación multinivel reveló una arquitectura compleja en los datos de homicidios colombianos que complementa y enriquece los hallazgos del análisis exploratorio y las reglas de asociación.

1) Hallazgos Estructurales:

- **Nivel Nacional:** La identificación de dos patrones densos principales junto con casos atípicos confirma la coexistencia de modalidades sistemáticas de violencia con fenómenos excepcionales. La ausencia de un "codo" claro en las métricas de evaluación sugiere la naturaleza continua y multifacética del fenómeno violento en Colombia.
- **Nivel Local:** El análisis de Bogotá demostró que la segmentación geográfica permite mayor precisión en la caracterización de patrones, revelando especificidades urbanas que no emergen en el análisis nacional. La identificación de un cluster específico asociado a terrorismo/conflicto armado ilustra la capacidad del análisis para detectar fenómenos locales particulares.

2) Contribución Metodológica:

- La implementación de múltiples algoritmos de clustering proporcionó perspectivas complementarias sobre la estructura latente de los datos. DBSCAN se destacó por su capacidad para identificar clusters de densidad variable y manejar ruido, características particularmente relevantes para datos criminológicos que inherentemente contienen casos atípicos significativos.
- El enfoque multinivel (nacional-local) demostró ser fundamental para capturar tanto patrones generales como es-

pecificidades regionales, proporcionando una base sólida para el diseño de estrategias diferenciadas de prevención y control de la violencia que consideren tanto las tendencias nacionales como las dinámicas locales específicas.

Basándose en los perfiles identificados mediante técnicas de clustering y los patrones revelados a través del análisis de reglas de asociación, se evidenció la relevancia de la variable circunstancia del hecho como un factor central en la caracterización de los homicidios. A partir de esta observación, se desarrolló un sistema de clasificación supervisada orientado a predecir dicha circunstancia, con el objetivo de aportar herramientas útiles para la prevención y el análisis diferenciado de la violencia.

VII. CLASIFICACIÓN DE CIRCUNSTANCIAS DE HOMICIDIOS

A. Metodología de Clasificación

Para abordar el problema de clasificación de las circunstancias de homicidios en Colombia, se implementó un *pipeline* completo de aprendizaje automático que incluye tanto modelos tradicionales como redes neuronales. El objetivo principal fue desarrollar un sistema capaz de predecir las circunstancias del hecho basándose en las características disponibles de cada caso.

1) *Preparación de Datos*: La preparación de datos se basó en los hallazgos del análisis exploratorio previo (Sección VI). Se seleccionaron las variables más relevantes identificadas en la fase de exploración:

- **Víctima**: Sexo, grupo de edad, escolaridad, ancestro racial
- **Hecho**: Zona, escenario, departamento, mecanismo causal, diagnóstico topográfico
- **Agresor**: Presunto agresor, pertenencia grupal

Se implementó una estrategia de limpieza que eliminó los casos clasificados como “Sin información” en la variable objetivo, resultando en un dataset final con observaciones válidas. La codificación de variables categóricas se realizó mediante *One-Hot Encoding*, implementando una estrategia de reducción dimensional.

2) *Modelos Implementados*: Se evaluaron seis modelos de clasificación divididos en dos categorías principales. Los modelos tradicionales incluyeron Random Forest con balanceamiento de clases, Gradient Boosting y Naive Bayes Multinomial. Las redes neuronales comprendieron tres arquitecturas: Simple (una capa oculta de 100 neuronas), Profunda (dos capas de 100 y 50 neuronas) y Compleja (tres capas de 150, 100 y 50 neuronas), todas con activación ReLU, optimizador Adam y parada temprana. Los datos se dividieron estratificadamente en conjuntos de entrenamiento (31,875 observaciones) y prueba (7,969 observaciones). Para las redes neuronales se aplicó estandarización mediante StandardScaler. La evaluación se realizó usando validación cruzada estratificada de 5 pliegues con F1-Score ponderado como métrica principal para manejar el desbalance de clases.

3) *Estrategia de Evaluación*: La evaluación se realizó mediante:

- Validación cruzada estratificada de 5 pliegues
- División 80-20 para entrenamiento-prueba
- Métricas principales: F1-Score ponderado y accuracy

B. Resultados de Clasificación

TABLE II
RENDIMIENTO COMPARATIVO DE MODELOS DE CLASIFICACIÓN

Modelo	CV F1-Score	Test Accuracy	Test F1-Score
Random Forest	0.652	0.623	0.640
Gradient Boosting	0.738	0.742	0.730
Naive Bayes	0.697	0.714	0.691
Neural Network Simple	0.729	0.738	0.725
Neural Network Deep	0.729	0.734	0.721
Neural Network Complex	0.729	0.740	0.724

1) *Rendimiento Comparativo de Modelos*: Los resultados demuestran que Gradient Boosting emergió como el modelo con mejor rendimiento general, alcanzando un F1-Score de validación cruzada de 0.717 (± 0.005) y un F1-Score de prueba de 0.709, con una precisión de 72.8%. Este modelo superó consistentemente a todas las demás alternativas evaluadas, mostrando robustez ante el desbalance de clases y capacidad de capturar patrones complejos en los datos. Las redes neuronales mostraron un rendimiento competitivo pero inferior a Gradient Boosting. La red neuronal simple alcanzó el mejor desempeño entre las arquitecturas neuronales con F1-Score de validación cruzada de 0.707 (± 0.016) y F1-Score de prueba de 0.699, convergiendo en apenas 18 iteraciones con un loss final de 0.5675. Paradójicamente, las arquitecturas más complejas (profunda y compleja) no mejoraron el rendimiento, sugiriendo que la complejidad adicional no aporta valor discriminativo para este problema específico. Los modelos tradicionales restantes mostraron rendimientos variados: Naive Bayes alcanzó un F1-Score de prueba de 0.668 y Random Forest obtuvo 0.650.

2) *Importancia de Características*: Al realizar el análisis de importancia de características del modelo Gradient Boosting se presentaron como variables más discriminativas son el mecanismo causal, específicamente “Corto punzante” (16.1% de importancia) y “Proyectil de arma de fuego” (15.3%). El presunto agresor también mostró alta relevancia, particularmente las categorías ELN (6.6%), Fuerzas militares (6.3%) y Otros (5.6%), evidenciando la importancia del contexto del conflicto armado en la clasificación. Variables geográficas como el departamento del Atlántico (2.3% de importancia) y características relacionales como “Compañero permanente” (2.2%) y “Conocido sin ningún trato” (2.1%) también contribuyen significativamente a la discriminación entre circunstancias. Estos hallazgos confirman la relevancia forense de elementos tradicionalmente considerados en la investigación criminal y validan el enfoque metodológico adoptado.

C. Búsqueda de Hiperparámetros

Se implementó búsqueda en grilla para optimizar los hiperparámetros de Gradient Boosting, explorando 27 combina-

ciones de parámetros clave. La configuración óptima incluyó learning rate de 0.1, profundidad máxima de 6 y 150 estimadores, resultando en una mejora marginal del F1-Score de validación cruzada a 0.714 y del F1-Score de prueba a 0.711. Aunque las mejoras fueron modestas, confirman la robustez de la configuración inicial y la estabilidad del modelo.

D. Discusión

Los resultados demuestran la viabilidad de usar aprendizaje automático para clasificar circunstancias de homicidios, aunque con limitaciones:

- El desbalance de clases afecta el rendimiento en categorías minoritarias.
- La calidad variable de los datos originales impacta los resultados.
- Algunas circunstancias son intrínsecamente difíciles de distinguir.

El sistema desarrollado podría automatizar el procesamiento inicial de casos forenses, aunque se recomienda su uso como herramienta de apoyo más que como sistema autónomo.

VIII. CONCLUSIÓN

Este trabajo presenta un enfoque integral de minería de datos para la caracterización y clasificación de homicidios en Colombia durante el período 2015-2023. La metodología desarrollada abarca desde el análisis exploratorio inicial hasta la implementación de modelos predictivos, demostrando la viabilidad de aplicar técnicas avanzadas de ciencia de datos a problemas criminológicos complejos.

El análisis exploratorio y preprocesamiento fueron fundamentales para transformar un conjunto de datos crudo en una base sólida para análisis posteriores. Se identificaron y abordaron problemas críticos como valores faltantes heterogéneos (64.16% en "Circunstancia del Hecho"), inconsistencias en codificación, y variables no informativas. Las técnicas de evaluación de relaciones (V de Cramer, Chi-cuadrado, entropía) resultaron cruciales para la selección objetiva de características.

La aplicación de algoritmos de reglas de asociación (Apriori y FP-Growth) reveló patrones específicos de riesgo previamente no evidentes. Se identificaron reglas significativas que caracterizan perfiles diferenciados, incluyendo patrones de violencia urbana con arma blanca (lift: 1.37), asociaciones entre víctimas jóvenes y armas de fuego (lift: 1.30), y perfiles específicos de violencia de género donde el uso de armas de fuego se asocia fuertemente con contextos de vía pública.

El análisis de agrupación multinivel (nacional y local) reveló estructuras latentes complejas. A nivel nacional, DBSCAN identificó cuatro perfiles principales con un coeficiente de silueta de 0.824, incluyendo patrones de violencia interpersonal dominante, perfiles específicos de violencia de género, y casos atípicos relevantes. El análisis específico de Bogotá (coeficiente de silueta: 0.826) descubrió dinámicas urbanas particulares, incluyendo un cluster asociado a terrorismo/conflicto armado.

Finalmente, la implementación de modelos de clasificación supervisada demostró la viabilidad de predecir circunstancias

de homicidios con un rendimiento aceptable. Gradient Boosting emergió como el mejor modelo, superando a redes neuronales y otros algoritmos tradicionales. El análisis de importancia de características confirmó la relevancia del mecanismo causal y el presunto agresor como variables discriminativas principales.

En conjunto, estos análisis proporcionan una base metodológica robusta para futuras investigaciones criminológicas y para el diseño de políticas públicas de prevención más focalizadas. Los perfiles de riesgo identificados, los patrones de asociación descubiertos, y las capacidades predictivas desarrolladas ofrecen herramientas concretas para la toma de decisiones basada en evidencia, adaptadas a los distintos contextos territoriales y modalidades de violencia en Colombia.

Las limitaciones principales incluyen el desbalance inherente en los datos, la calidad variable de la información original, y la necesidad de validación externa de los modelos. Trabajos futuros podrían explorar la incorporación de variables socioeconómicas adicionales, la aplicación de técnicas de deep learning más avanzadas, y la validación de los perfiles identificados con datos de otras fuentes institucionales.

REFERENCES

- [1] "Presuntos Homicidios. Colombia, 2015 a 2023. Cifras definitivas — Datos Abiertos Colombia," Dec. 05, 2024. <https://www.datos.gov.co/Justicia-y-Derecho/Presuntos-Homicidios-Colombia-2015-a-2023-Cifras-d/vtub-3de2>.
- [2] J. McHugh, "The Chi-square test of independence," *Biochemia Medica*, vol. 23, no. 2, pp. 143–149, Jun. 2013.
- [3] D. J. Sheskin, *Handbook of Parametric and Nonparametric Statistical Procedures*, 5th ed. Boca Raton, FL: CRC Press, 2011.
- [4] P. Tan, M. Steinbach, A. Karpatne, and V. Kumar, *Introduction to Data Mining*, 2nd ed. Pearson, 2018.
- [5] C. E. Shannon, "A Mathematical Theory of Communication," *Bell System Technical Journal*, vol. 27, pp. 379–423, 623–656, 1948.
- [6] K. Backhaus, B. Erichson, W. Plinke, and R. Weiber, *Multivariate Analysemethoden: Eine anwendungsorientierte Einführung*, 14th ed. Springer Gabler, 2016.